

Aplicação de ciência das redes para analisar sistemas de recomendação de produtos em sites de e-commerce

Adryan Castro Feres¹, Vitor Kenji Zoppo Yamada²

¹Universidade Tecnológica Federal do Paraná (UTFPR)
Curitiba – PR – Brasil

`adryancastro@alunos.utfpr.edu.br, vitoryamada@alunos.utfpr.edu.br`

1. Introdução

O crescimento do comércio online transformou a maneira como os consumidores interagem com o mercado. Nesse contexto, os sistemas de recomendação desempenham um papel crucial, atuando como intermediários que personalizam a experiência de navegação, sugerindo itens relevantes com base no comportamento histórico dos usuários e nas características dos produtos.

O problema central deste trabalho é a predição de novas interações comerciais em sistemas de recomendação: a partir do histórico de compras e avaliações, busca-se estimar se um usuário tende a adquirir um determinado produto.

Para isso, os dados são representados através de uma modelagem de rede, em que usuários e produtos são representados como nós de um grafo e suas interações como arestas. A partir dessa modelagem, são aplicados os conceitos de Ciência de Dados, explorando por propriedades topológicas e atributos dos nós, em combinação com técnicas de aprendizado de máquina supervisionado, para realizar a tarefa de predição de arestas.

2. Descrição dos dados estudados

A rede analisada foi construída a partir de avaliações de produtos da Amazon, disponibilizadas em um conjunto de dados público com cerca de 25 GB de registros brutos [1]. Para tornar a análise viável e focar em interações mais informativas, foi aplicado um pré-processamento que selecionou apenas usuários com mais de 60 avaliações e produtos com mais de 1.200 avaliações, além da remoção de colunas consideradas irrelevantes. Em outras palavras, um corte no grafo original foi selecionado.

Após essa etapa, obteve-se uma rede bipartida usuário–produto mais densa e estruturada, contendo aproximadamente 17 mil nós (cerca de 13,3 mil usuários e 3,7 mil produtos) e 172 mil arestas, em que cada aresta representa uma avaliação realizada por um usuário em um produto.




Figura 1. Visualização da rede bipartida no Gephi

Na visualização 1, nós em vermelho representam **produtos** e nós em azul representam **usuários**. Na primeira imagem as arestas foram ocultadas para destacar apenas a distribuição dos nós na rede bipartida, enquanto na segunda os tamanhos dos nós foram escalonados de acordo com o *degree*, tornando maiores os vértices com maior grau. Essa configuração evidencia que os produtos tendem a receber bem mais arestas (avaliações) do que a maioria dos usuários, formando hubs de produtos altamente conectados.

As medidas globais calculadas no Gephi indicam um grau médio em torno de 10 e uma densidade de aproximadamente 0,001, caracterizando uma rede grande e ainda esparsa, na qual cada usuário se conecta a poucos produtos e vice-versa. A análise de componentes conectados mostra que praticamente todos os nós pertencem a uma única grande componente, condição importante para o uso de métricas globais de centralidade e para a tarefa de predição de links.

3. Metodologia e técnicas utilizadas

A metodologia adota como principal objetivo a predição de links: a rede observada é interpretada como um “instantâneo” parcial do sistema, a partir do qual se tenta inferir arestas ausentes que poderiam existir no futuro. Adicionalmente, foram adicionados exemplos de arestas que não existem na rede original, rotulando-se com 1 as arestas que existem de fato, e com 0 as arestas que não existem, balanceando a base de dados. O trabalho combina análise de propriedades da rede, construção de features estruturais e aprendizado supervisionado para aproximar um sistema de recomendação de produtos.

3.1. Cálculo de métricas e centralidades

Inicialmente foram calculadas métricas clássicas de centralidade sobre a rede bipartida, tanto para usuários quanto para produtos: grau, PageRank, closeness e EigenVector, seguindo as definições discutidas nas aulas de centralidade. Essas métricas capturam, respectivamente, a conectividade local, a importância global em termos de fluxo de informação, a proximidade média em relação aos demais nós e a influência estrutural associada a vizinhos importantes.

Em seguida, foi construída a projeção da rede no conjunto de produtos: dois produtos são conectados na projeção se houver pelo menos um usuário que avaliou ambos, e essa ligação recebe um peso de similaridade calculado por métricas locais de vizinhança, sendo elas o número de vizinhos comuns, Preferential-Attachment, o coeficiente de Jaccard e índice de Adamic–Adar.

Esses valores são usados posteriormente como features.

3.2. Detecção de comunidades

O algoritmo de Louvain foi aplicado em cada projeção da rede bipartida original para a detecção de comunidades, identificando grupos de elementos semelhantes. Como resultado, foram detectadas 7 comunidades na projeção de usuários e 3 na projeção de produtos.

Para as comunidades de produtos, foram calculadas métricas descritivas, incluindo preço médio, nota média, número médio de avaliações e a categoria predominante.

A análise das comunidades de produtos detectadas permitiu concluir as seguintes características distintas:

- **Comunidade 1 (Itens Populares):** Caracterizada como um conjunto de itens mais populares, apresentando o menor preço médio e o maior número médio de avaliações. A categoria predominante é a de **eletrônicos gerais**.
- **Comunidade 2 (Itens de Alto Valor):** Apresenta o maior preço médio e o menor número médio de avaliações (produtos menos avaliados). Sua categoria predominante é a de **computadores**.
- **Comunidade 3 (Itens Intermediários):** Possui valores intermediários de preço e de número de avaliações. Esta comunidade também está enquadrada na categoria de **computadores**.

Outro padrão interessante encontrado foi o fato de a nota média do produto ser aproximadamente constante em cada comunidade, evidenciando que, independente da comunidade, os itens mais comprados pelos consumidores são bem avaliados.

3.3. Link Prediction

A tarefa de recomendação foi modelada como um problema de predição de links (*link prediction*) no grafo bipartido. Adotou-se uma abordagem de aprendizado supervisionado utilizando Redes Neurais de Grafos (GNNs) para criar um classificador binário capaz de inferir a existência de arestas entre usuários e produtos.

Para o treinamento, utilizou-se amostragem negativa (*negative sampling*) para balancear as classes, gerando uma proporção de 1:1 entre arestas existentes (positivas) e arestas inexistentes geradas aleatoriamente (negativas).

Especificação da Arquitetura e Treinamento

A rede neural implementada opera com uma dimensão de *embedding* de 128 características latentes. A arquitetura é composta por uma sequência de três camadas convolucionais de grafos. Cada camada intermediária mantém a dimensionalidade de 128 neurônios e é seguida por:

1. Normalização em lote (*Batch Normalization*);
2. Função de ativação não-linear ReLU (*Rectified Linear Unit*);
3. Camada de *Dropout* com probabilidade $p = 0.3$ para regularização.

Para a classificação final do par usuário-produto, os vetores resultantes de 128 dimensões de cada nó são concatenados (resultando em um vetor de entrada de 256 posições) e processados por uma camada linear densa, seguida de uma projeção para um único neurônio de saída.

O processo de otimização seguiu os seguintes hiperparâmetros:

- **Otimizador:** AdamW, com taxa de aprendizado inicial de 5×10^{-4} e decaimento de peso (*weight decay*) de 1×10^{-5} ;
- **Ciclo de Treinamento:** Máximo de 100 épocas;
- **Controle de Taxa de Aprendizado:** Redução da taxa (fator 0.5) após 5 épocas sem melhoria na função de perda;
- **Critério de Parada:** *Early Stopping* com paciência de 15 épocas, monitorando a métrica F1-Score no conjunto de validação.

4. Resultados

Após o treinamento do modelo de classificação, o desempenho da predição de links foi avaliado utilizando as métricas de Precisão, Recall (Revocação) e F1-Score. A escolha dessas métricas fundamenta-se na necessidade estratégica de penalizar severamente a ocorrência de Falsos Negativos. No contexto deste domínio, a omissão de uma recomendação relevante (Falso Negativo) é considerada um erro mais crítico do que a sugestão de um item que não gera interesse (Falso Positivo). Não sugerir um produto que certamente seria adquirido por um consumidor é um cenário grave em nosso estudo.

No melhor cenário reportado, o modelo alcançou as seguintes métricas de desempenho:

- **Precision:** $\approx 0,55$
- **Recall:** $\approx 0,97$
- **F1-score:** $\approx 0,70$
- **AUC:** $\approx 0,75$

Além disso, a matriz de confusão e a curva ROC apresentadas abaixo reforçam o desempenho do modelo. A alta taxa de verdadeiros positivos, evidenciada pelo Recall elevado, indica que o classificador consegue identificar a maior parte dos links relevantes. Por outro lado, a curva ROC demonstra que o modelo mantém bom equilíbrio entre taxa de acertos e taxa de falsos alarmes ao longo de diferentes limiares de decisão. Esses resultados, quando considerados em conjunto, sugerem que o modelo é consistente para aplicações em que a recuperação de recomendações relevantes é prioritária, mesmo que isso implique uma taxa moderada de falsos positivos.




Figura 2. Matriz de confusão do modelo supervisionado




Figura 3. Curva ROC do modelo supervisionado

5. Conclusão

A análise realizada demonstrou que a modelagem de uma rede de avaliações de produtos, escritas por consumidores, como uma **rede bipartida usuário–produto** permite aplicar de forma efetiva os conceitos de Ciência das Redes e aprendizado supervisionado para predição de links, extraindo conhecimento sobre os padrões de compras em sites de e-commerce.

Adicionalmente, o modelo construído para predição de links obteve um resultado satisfatório, evidenciando que sites de e-commerce certamente utilizam metodologias semelhantes para recomendar produtos para consumidores, e se ainda não utilizam um sistema de recomendação, tanto usuário quanto comerciante podem se beneficiar de tal modelo classificador.

Por fim, através do estudo realizado, conclui-se que predição de links na área de comércio é benéfico tanto para consumidores quanto para vendedores de produtos e

serviços, além de que pode ser aplicado para outras áreas, como streaming de filmes (e.g. Netflix), música (e.g. Spotify), entre outros.

Referências

- [1] McAuley Lab. Amazon reviews 2023 dataset. <https://amazon-reviews-2023.github.io/>. Accessed: 2025-12-09.